

پرسش تئوری ۱

۱.

هر دارو یک بازو است (در مجموع دو بازو) و پاداش را می توان به صورت نرخ احتمال موفقیت که یک عدد حقیقی بین صفر و یک است مدل کرد. در این مثال بهره برداری به معنای پایبندی به یک دارو و استفاده مکرر از آن است، در حالی که اکتشاف به معنای آزمایش هر دو دارو است. در این مورد خاص، چون ما فقط ۲ بازو داریم اکتشاف گزینه بهتری است.

۲.

هر صفحه تبلیغاتی یک بازو است و پاداش تعداد کلیک های روی هر تبلیغ است یا زمان دیدن تبلیغ است. اکتشاف به معنای پرسش بین صفحات مختلف تبلیغ است و بهره برداری به معنای تبلیغ جذابیت بیشتری بین مشتری ها داشته باشد. اینجا هم اکتشاف و هم بهره برداری باید همراه هم باشند که به هر دو نیاز است.

۳.

در این مورد، هر ژانر فیلم میتواند یک بازو در نظر گرفته شود و پاداش می تواند به عنوان رضایت کلی بیننده مدل سازی شود. رضایت را میتوان با یک نظرسنجی یافت. هم بهره برداری و هم اکتشاف (تنوع در پیشنهاد فیلم) برای کار واجب است و باید همراه هم باشند.

پرسش تئوری ۲

۱.

در این سوال، هر ژانر یک بازو و هر پیشنهاد فیلم یک مرحله است. مدل پاداش دهنده، سیستم امتیازدهی از ۰ تا ۵ است.

۲.

یک استراتژی ساده که فقط از آن استفاده میشود، زمانی است که به طور تصادفی از بین ژانرها انتخاب میکنیم، اما به ژانرهای مختلف بسته به امتیاز، وزن های مختلف میدهیم.

۳.

یک رویکرد بسیار مستقیم به موضوع، انتخاب تصادفی ژانر است که در آن هر ژانر با یم بار انتخاب، از مجموعه خارج میشود. این استراتژی ممکن است منجر به رضایت کلی ضعیفی شود، زیرا هیچ کس همه ژانر های موجود را دوست ندارد.

۴.

یک استراتژی نسبتاً خوب باید هم کاوش و هم بهره برداری را به طور متناسب داشته باشد و باید سعی کند ژانر مورد علاقه دانش آموز را پیشنهاد دهد، در حالی تصادفی بودن را برای پیشنهاد ژانرهای مختلف داشته باشد.

پرسش تئوری ۳

۱.

$$E[r_t | A_t = i] = 1 \times p[r_t = 1] + 0 \times p[r_t = 0] = p[r_t] = \mu_i$$

۲.

نشانگر $1\{A_t = i\}$ فقط زمانی یک است که بازوی i ام را انتخاب کرده باشیم و در غیر این صورت صفر است. بنابراین، جمع زدن این یک ها در طول زمان از $t = 1$ تا T دقیقاً تعداد دفعات انتخاب بازوی i را به ما می دهد.

۳.

$$E[S_T] = E\left[\sum_{t=1}^T r_t\right] = E\left[\sum_{t=1}^T \sum_{i=1}^k 1\{A_t = i\} \mu_i\right] = E\left[\sum_{i=1}^k \mu_i N_i(T)\right] = \sum_{i=1}^k \mu_i E[N_i(T)]$$

پرسش تئوری ۴

۱.

$$\hat{\mu}_i(n) = \frac{1}{n} \sum_{s=1}^n X_{i,s} \implies E[\hat{\mu}_i(n)] = \frac{1}{n} \sum_{s=1}^n E[X_{i,s}] = \frac{1}{n} \sum_{s=1}^n \mu_i = \mu_i$$

۲.

محاسبه واریانس میانگین تجربی:

$$Var(\hat{\mu}_i(n)) = Var\left(\frac{1}{n} \sum_{s=1}^n X_{i,s}\right) = \frac{1}{n^2} \sum_{s=1}^n Var(X_{i,s}) = \frac{n\mu_i(1-\mu_i)}{n^2} = \frac{\mu_i(1-\mu_i)}{n}$$

۳.

نتیجه گیری: با بزرگ شدن n ، واریانس به سمت صفر میل کرده و طبق قانون اعداد بزرگ، میانگین تجربی به میانگین واقعی نزدیک می شود.

پرسش تئوری ۵

آ

$$E[S_T] = \sum_{i=1}^k \mu_i E[N_i(T)]$$

اگر در تمام زمان ها بازوی بهینه انتخاب شود:

$$E[S_T] = \mu^* E[N_{i^*}(\tau)] = \mu^* E\left[\sum_{t=1}^T 1\right] = T\mu^*$$

در این حالت، پشیمانی (Regret) برابر با صفر خواهد بود:

$$Regret(T) = T\mu^* - E[S_T] = 0$$

ب

$$Regret(T) = T\mu^* - E[S_T] = \sum_{i=1}^k \mu^* E[N_i(T)] - \sum_{i=1}^k \mu_i E[N_i(T)] = (\mu^* - \mu_i) E[N_i(\tau)] = \sum_{i=1}^k \Delta_i E[N_i(\tau)]$$

ج

باید وزن خطا بازو در متوسط تعداد دفعات آن دیده شود یعنی بازوهای بد و تعداد بالا پشیمانی را زیادتر میکنند.

پرسش تئوری ۶

آ

k بازو داریم که همگی احتمال یکسان $\frac{1}{k}$ برای انتخاب دارند اگر احتمال انتخاب بازوی i را بخواهیم:

$$\binom{T}{i} \left(\frac{1}{k}\right)^i \left(1 - \frac{1}{k}\right)^{T-i}$$

بنابراین $N_i(T) \sim \text{Bin}(T, \frac{1}{k})$ بنابر خاصیت متغیر:

$$E[N_i] = \frac{1}{k} \cdot T = \frac{T}{k}$$

ب

$$Regret(T) = \sum_{i=1}^k \Delta_i E[N_i(T)] = \sum_{i=1}^k \Delta_i \frac{T}{k} = \frac{T}{k} \sum_{i=1}^k \Delta_i$$

ج

سیاست یکنواخت:

$$Regret(1000) = \frac{1000}{2}(0 + 0.3) = 150$$

سیاست بهترین بازو:

$$Regret(1000) = 0$$

پرسش تئوری ۷

۱.

چون اکتشاف کافی نداشتیم می تواند ورق برای بازویی که تا آن لحظه کمتر پاداش گرفته برگردد و یک رگرت بزرگ ایجاد شود.

۲.

می تواند بهتر یا بدتر باشد چرا که ممکن است اکتشاف A بهینه باشد.

۳.

سیاست C چون یک تعادل خوب بین اکتشاف و بهره برداری ایجاد کرده است معمولا از دو سیاست قبلی بهتر است.

پرسش تئوری ۸

۱.

$$p(|\bar{Y}_n - m| \geq \epsilon) \leq 2\exp(-2n\epsilon^2)$$

با جایگذاری اپسیلون:

$$p(|\bar{Y}_n - m| \geq C_n(\delta) \leq 2\exp(-2n \frac{\ln \frac{2}{\delta}}{2n}) = 2\exp(\ln \frac{\delta}{2}) = \delta \Rightarrow p(|\bar{Y}_n - m| \leq C_n(\delta)) \geq 1 - \delta$$

۲.

به احتمال حداقل $1 - \delta$ میانگین واقعی در فاصله $\sqrt{\frac{\ln \frac{2}{\delta}}{2n}}$ با میانگین تجربی است.

۳.

بخش $\hat{\mu}_i(t)$ سهم بهره برداری است یعنی بازویی که میانگین تجربی بیشتری داشته است. از طرفی $C_i(t)$ نیز سهم اکتشاف است، هر چقدر تعداد دفعات یک بازی با بازو کمتر باشد این مقدار بزرگ تر می شود یعنی باید سراغ آن رفت تا اکتشاف کامل تر شود.

پرسش تئوری ۹

توزیع برنولی به فرم $x^r(1-x)^n - r$ است و توزیع بتا ب فرم $x^{\alpha-1}(1-x)^{\beta-1}$ است. وقتی این دو توزیع در هم ضرب میشوند، حاصل ضرب همچنان به فرم $x^A(1-x)^B$ باقی مانده که همان ساختار توزیع بتا است. این ویژگی باعث میشود که برای بروزرسانی در یک بازو، نیاز به حل انتگرال نباشد و فقط پارامترها به روز رسانی شوند.

اگر پاداش یک بود: $\alpha \rightarrow \alpha + 1$

اگر پاداش صفر بود: $\beta \rightarrow \beta + 1$

پرسش تئوری ۱۰

$$\begin{aligned}p(\mu|data) &\propto p(data|\mu)p(\mu) \\p(\mu) &= \mu^s(1-\mu)^f; p(data|\mu) = \frac{1}{B(\alpha, \beta)}\mu^{\alpha-1}(1-\mu)^{\beta-1} \\p(\mu|data) &\propto \mu^{\alpha+s-1}(1-\mu)^{f+\beta-1}\end{aligned}$$

که هسته توزیع $Beta(\alpha + s, \beta + f)$ است.

پرسش تئوری ۱۱

$$\begin{aligned}f_X(x; \alpha', \beta') &= \frac{1}{B(\alpha', \beta')}x^{\alpha'}(1-x)^{\beta'-1} \\E[X] &= \frac{1}{B(\alpha', \beta')} \int_0^1 x^{\alpha'}(1-x)^{\beta'-1}dx = \frac{B(\alpha' + 1, \beta')}{B(\alpha', \beta')} = \frac{\Gamma(\alpha' + 1)}{\Gamma(\alpha')} \frac{\Gamma(\alpha' + \beta')}{\Gamma(\alpha' + \beta' + 1)} = \frac{\alpha'}{\alpha' + \beta'}\end{aligned}$$

پرسش تئوری ۱۲

ما مقدار دقیق μ را نمیدانیم، اما توزیع آن $Beta(\alpha, \beta)$ می باشد و می توان روی مقادیر مختلف آن انتگرال گرفت.

$$\begin{aligned}p(X_t + 1 = 1|data) &= \int_0^1 p(X_t + 1 = 1|\mu)p(\mu|data)d\mu \\&\text{طبق خاصیت برنولی } p(X_t + 1 = 1|\mu) \text{ همان } \mu \text{ است پس انتگرال بالا همان } E[\mu|data] \text{ می باشد.} \\&\Rightarrow E[\mu|data] = \frac{\alpha}{\alpha + \beta}\end{aligned}$$

پرسش تئوری ۱۳

Thompson احتمالاً بازوی دوم را انتخاب میکند چرا که واریانس کمتری دارد و میانگین آن نیز کمی بیشتر است پس شانس اکتشاف همراه با شانس بهره برداری میشود.

پرسش تئوری ۱۴

نمونه گیری تامپسون به رگرت لگاریتمی مجانبی دست می یابد زیرا از طریق نمونه گیری پسین، اکتشاف و بهره برداری را به شیوه بهینه بیزی متعادل میکند و بنابراین بهترین الگوریتم است.

پرسش تئوری ۱۵

دلیل اصلی کارآمدی این روش، تبدیل یک انتگرال پیچیده و چندبعدی به یک شبیه‌سازی ساده است. محاسبه مستقیم احتمال اینکه یک بازو (μ_i مثل μ_i) بهترین باشد، مستلزم حل انتگرالی دشوار روی توزیع‌های پسین تمام بازوهاست؛ اما با «نمونه‌برداری از پسین»، ما به سادگی از توزیع هر بازو یک عدد تصادفی می‌گیریم و بازویی که بزرگترین عدد را داشته باشد انتخاب می‌کنیم. این کار به صورت خودکار باعث می‌شود هر بازو دقیقاً به اندازه «احتمال بهینه بودنش» شانس انتخاب شدن داشته باشد.

پرسش تئوری ۱۶

۱.

رفتار: این توزیع کاملاً مسطح است و هیچ پیش‌فرضی درباره بازو بهتر ندارد. اکتشاف اولیه: بسیار بالا؛ چون اطلاعاتی ندارد، در ابتدا به همه بازوها شانس برابری برای انتخاب شدن می‌دهد. سوگیری: بدون سوگیری (Unbiased)؛ به سرعت با داده‌های جدید (پاداش‌ها) به‌روز شده و منعطف عمل می‌کند.

۲.

رفتار: این توزیع شبیه به یک زنگوله باریک روی عدد 0.5 است و نشان‌دهنده اطمینان بسیار زیاد اولیه است. اکتشاف اولیه: بسیار پایین؛ به دلیل «سختی» (Inertia) بالای این توزیع، نمونه‌های استخراج شده همگی نزدیک به 0.5 خواهند بود. سوگیری: دارای سوگیری شدید؛ الگوریتم برای تغییر عقیده نسبت به این بازو به داده‌های بسیار زیادی نیاز دارد. عملاً باعث می‌شود سیستم در ابتدا نسبت به یادگیری مقادیر واقعی بازوها مقاومت کند.

۳.

رفتار: تمرکز این توزیع روی مقادیر صفر و یک است (یعنی بازو یا خیلی بد است یا خیلی خوب). اکتشاف اولیه: تهاجمی؛ این پیشین باعث می‌شود الگوریتم تمایل داشته باشد بازوها را تا حد افراطی امتحان کند تا بفهمد بالاخره «خوب» هستند یا «بد». سوگیری: سوگیری ضعیف به سمت کرانه‌ها؛ این توزیع برای زمانی که انتظار داریم تفاوت بین بازوها فاحش باشد (مثلاً نرخ تبدیل یا صفر است یا یک) بسیار عالی عمل می‌کند و سریع‌تر از حالت یکنواخت به نتیجه می‌رسد.
